Superfamilles de réseaux complexes

Projet AAGA — Sujet 7

Rapport expérimental — comptage de graphlets, modèle nul préservant les degrés et profils SRP

Statut : implémentation et quatre expériences exécutées ; résultats exploratoires. La comparaison couvre les réseaux sociaux et un réseau littéraire ; la généralisation reste non démontrée.

Reproductibilité : code Python, tests, script Bash et résultats CSV/JSON/PNG fournis dans le même dossier.

Référence scientifique principale : Milo et al., *Science* (2004).

1. Résumé et objectifs

Le projet étudie si des réseaux réels peuvent être regroupés en « superfamilles » à partir de la fréquence relative de petits motifs structuraux. Deux réseaux de tailles différentes ne sont pas directement comparables par leurs nombres bruts de motifs. Une comparaison à des graphes aléatoires qui conservent les degrés permet de construire un profil normalisé, appelé ici subgraph ratio profile (SRP).

L'objectif pratique est de compter les six motifs connexes induits à quatre sommets dans des graphes non orientés, puis de calculer leur enrichissement ou leur appauvrissement par rapport à un modèle nul. La question de recherche est la suivante : des réseaux distincts présentent-ils des signatures SRP similaires, au-delà de la seule distribution de leurs degrés ?

2. Périmètre du travail

• Implémentation Python d'un dénombrement exact des motifs connexes induits à quatre sommets.

• Génération de graphes aléatoires simples par échanges d'arêtes conservant les degrés.

• Calcul du SRP pour quatre réseaux documentés fournis par NetworkX.

• Production de fichiers JSON, CSV et d'un graphique comparatif ; tests unitaires.

Le travail présenté est un prototype expérimental reproductible. Trois réseaux sont sociaux et un réseau est littéraire (coapparition de personnages). Ce premier élargissement permet une comparaison entre deux domaines, mais pas une démonstration générale de superfamilles.

3. Concepts fondamentaux

Graphe non orienté : ensemble V de sommets et ensemble E d’arêtes non orientées. Le degré d’un sommet est le nombre de ses voisins. Un motif ou graphlet est une petite structure de connexions récurrente.

Motif induit : pour quatre sommets sélectionnés, on conserve toutes les arêtes qui existent réellement entre ces quatre sommets dans le graphe initial. Le motif n’est compté que si ces quatre sommets forment un sous-graphe connexe. Deux choix de sommets différents représentent deux occurrences distinctes, même si leurs formes sont identiques.

Modèle nul : on compare le réseau à des graphes de mêmes sommets et de mêmes degrés. Cela évite de considérer comme surprenante une abondance de motifs simplement causée par la présence de sommets très connectés.

Superfamille : groupe de réseaux présentant des profils de motifs proches. Une ressemblance visuelle entre deux courbes SRP peut suggérer une proximité, mais ne prouve pas à elle seule l’existence d’une famille stable.

4. Les six motifs à quatre sommets

Nom	Arêtes	Degrés internes triés	Interprétation
P4	3	1,1,2,2	Chemin de longueur 3
K1,3	3	1,1,1,3	Étoile à 3 feuilles
C4	4	2,2,2,2	Cycle à 4
Paw	4	1,2,2,3	Triangle + feuille
Diamond	5	2,2,3,3	Clique K4 sans une arête
K4	6	3,3,3,3	Clique complète

5. Algorithme de comptage

L’algorithme parcourt les arêtes du graphe et étend chaque paire connectée en un triplet connexe, puis en un quadruplet connexe. Chaque quadruplet est représenté par un ensemble immuable de sommets ; l’ensemble global de ces quadruplets élimine les doublons provenant de plusieurs chemins de construction.

Pour chaque quadruplet, le programme inspecte les six paires possibles de sommets, compte les arêtes induites et calcule les quatre degrés internes. Le nombre d’arêtes et la suite triée des degrés suffisent à distinguer les six graphlets connexes à quatre sommets.

Le choix de commencer par une arête et d’étendre uniquement vers un voisin garantit que tout quadruplet produit est connexe. Réciproquement, tout graphe connexe à quatre sommets possède une séquence de construction par ajouts de voisins ; il sera donc rencontré. Le dédoublonnage garantit qu’il n’est compté qu’une fois.

La méthode est exacte, mais sa mémoire et son temps de calcul augmentent avec le nombre de quadruplets connexes. Elle convient à des réseaux petits ou moyens, pas nécessairement à des graphes de millions de sommets. Les tests vérifient séparément les six motifs, l’absence de motifs dans un graphe vide et la conservation des degrés après randomisation.

6. Randomisation et modèle de configuration

Pour générer les graphes de référence, on effectue des échanges doubles d'arêtes (double-edge swaps). Deux arêtes sont remplacées par deux autres, sans changer le degré d'aucun sommet. Le résultat reste un graphe simple, sans boucle ni arête multiple. La connexité du graphe n'est pas imposée.

Cette méthode réalise un **modèle nul de graphes simples à degrés fixés**, proche de l'objectif du modèle de configuration. Elle n'est cependant pas identique au tirage direct de demi-arêtes du modèle de configuration multigraphe et ne garantit pas un échantillonnage uniforme de tous les graphes simples possibles.

Paramètres retenus : 20 graphes randomisés par réseau ; graine aléatoire 42 ; objectif de cinq échanges réussis par arête. Ces choix rendent les expériences répétables mais ne suffisent pas à évaluer la convergence statistique des résultats.

7. Calcul du subgraph ratio profile

Pour le motif i, on note N(i) son nombre observé et R(i) la moyenne des nombres observés dans les graphes randomisés. Le programme calcule :

Delta(i) = [N(i) − **R(i)] / [N(i) + R(i) + epsilon]**, avec epsilon = 4.

Puis **SRP(i) = Delta(i) / sqrt(somme_j Delta(j)²)**. Si tous les Delta sont nuls, le programme renvoie le vecteur nul.

Un SRP positif signifie que le motif est relativement enrichi par rapport au modèle nul ; une valeur négative signifie qu'il est relativement appauvri. La normalisation permet de comparer les formes des profils plutôt que leurs amplitudes brutes. Le pseudocompte epsilon stabilise les motifs très rares.

8. Jeux de données

Réseau	Sommets	Arêtes	Description
Karate	34	78	Relations sociales du club de karaté de Zachary
Florentine	15	20	Liens matrimoniaux entre familles florentines
Southern women	32	89	Réseau biparti de participation à des événements
Les Misérables	77	254	Coapparitions de personnages dans un roman

Les données sont chargées directement depuis les jeux d'exemple de NetworkX, ce qui évite d'imposer des téléchargements manuels et facilite la reproduction. Les quatre réseaux sont traités comme des graphes non orientés simples. Le réseau Les Misérables représente des coapparitions de personnages : il relève du domaine littéraire, bien que sa structure soit aussi une forme de réseau social fictif.

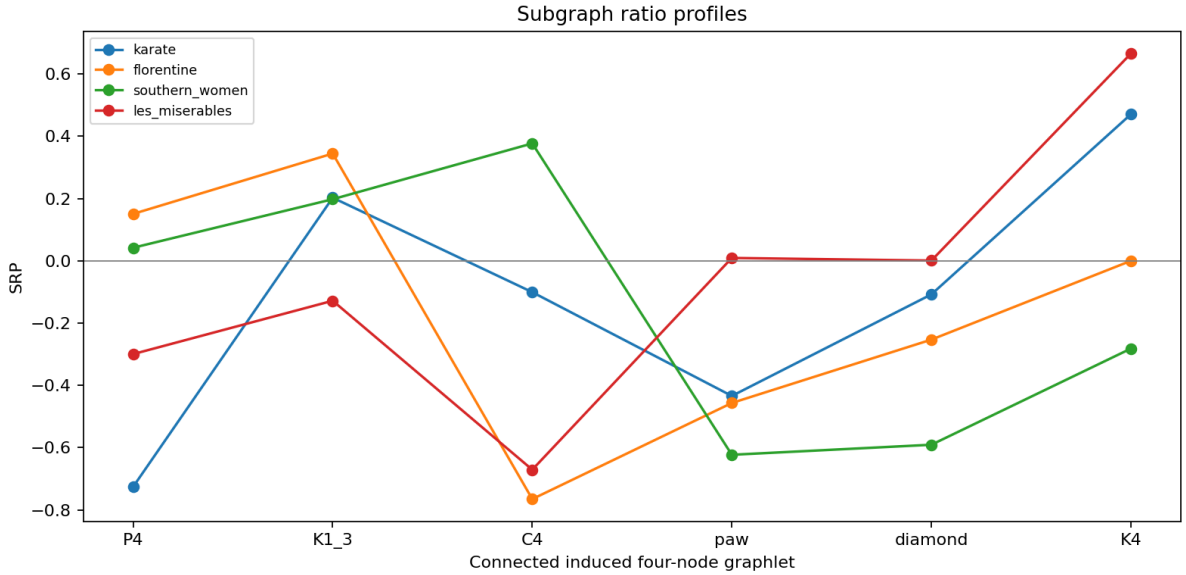
Le réseau Southern women est biparti : ses sommets appartiennent à deux types et ses arêtes ne relient que des types opposés. On conserve cette structure sans projection. Le modèle nul ne préserve que les degrés et non la bipartition ; il peut donc créer des triangles absents du graphe d'origine. Cette différence structurelle doit être prise en compte dans l'interprétation.

9. Plan expérimental

Pour chaque réseau : (1) compter les motifs induits ; (2) produire 20 réseaux aléatoires de même séquence de degrés ; (3) calculer les nombres moyens de motifs dans ces références ; (4) calculer les six valeurs Delta et leur normalisation SRP ; (5) tracer les quatre profils sur une figure commune.

10. Résultats numériques

Réseau	P4	K1,3	C4	Paw	Diamond	K4
karate	-0.726	0.203	-0.101	-0.434	-0.108	0.471
florentine	0.151	0.345	-0.765	-0.457	-0.253	0.000
southern_women	0.042	0.198	0.377	-0.623	-0.591	-0.282
les_miserables	-0.300	-0.128	-0.671	0.009	0.001	0.666



Les valeurs représentent des résultats calculés par le code fourni, avec 20 randomisations par réseau et une graine fixée. Le signe et la magnitude des valeurs doivent être lus relativement au modèle nul choisi, non comme des probabilités absolues.

11. Discussion des profils

Le réseau Karate présente un enrichissement relatif de K4 et, plus modérément, des étoiles K1,3 ; les chemins P4 et les motifs paw sont appauvris. Cela indique que les structures très fermées peuvent être plus présentes que dans les graphes randomisés de même distribution de degrés.

Le réseau Florentine se distingue par un appauvrissement marqué des cycles C4 et des motifs paw. Les étoiles sont légèrement enrichies. La faible taille du réseau limite la stabilité des estimations pour les motifs rares ; K4 peut être absent dans le graphe et dans les références.

Southern women se distingue par un enrichissement des cycles C4 et un appauvrissement des motifs contenant des triangles. Cette observation est attendue dans un graphe biparti, puisque les triangles y sont impossibles. Le résultat reflète en partie une propriété de type de réseau que le modèle nul retenu ne conserve pas.

Le réseau littéraire Les Misérables présente un profil calculé sur des coapparitions de personnages, mais sa proximité conceptuelle avec les réseaux sociaux empêche de le considérer comme une validation indépendante sur un réseau biologique ou technologique.

Les quatre profils ne sont pas identiques. Ils suggèrent que le SRP capte des différences structurales, mais ne permettent pas de définir des superfamilles fiables. Pour étudier la stabilité des regroupements, il faudrait davantage de réseaux par domaine et un critère de proximité quantifié, avec incertitudes sur les profils.

12. Limites et améliorations possibles

• **Diversité des domaines :** trois réseaux sociaux et un réseau littéraire. Ajouter des réseaux biologiques ou technologiques externes pour une validation interdisciplinaire forte.

• **Modèle nul :** les échanges d'arêtes préservent les degrés, mais pas les contraintes de bipartition ou d'autres attributs. Comparer avec des modèles nuls spécifiques.

• **Échantillonnage :** 20 randomisations ne garantissent pas la convergence ; répéter avec davantage de tirages, plusieurs graines et diagnostics de mélange.

• **Performance :** l'énumération exhaustive des quadruplets peut devenir coûteuse ; employer des méthodes optimisées ou de l'échantillonnage pour les grands graphes.

• **Inférence :** un profil similaire ne constitue pas une preuve de superfamille. Mesurer les distances entre profils et évaluer la stabilité des groupes.

13. Conclusion

Le projet fournit une chaîne reproductible de comptage des six graphlets connexes induits à quatre sommets, de randomisation préservant les degrés et de calcul de SRP. Les résultats montrent que des réseaux documentés présentent des signatures de motifs différentes, même après contrôle de leurs degrés. En revanche, l'étude élargie à un réseau littéraire ne permet pas encore de conclure à la généralité des superfamilles : cette hypothèse exige des réseaux biologiques et technologiques et des tests de robustesse.

14. Références et reproductibilité

[1] Milo, R., Itzkovitz, S., Kashtan, N., Levitt, R., Shen-Orr, S., Ayzenshtat, I., Sheffer, M., Alon, U. (2004). *Superfamilies of evolved and designed networks*. Science, 303(5663), 1538–1542. Référence imposée par le sujet ; la reproduction exacte des expériences de cet article n'est pas revendiquée.

[2] NetworkX, documentation et jeux de données intégrés : https://networkx.org/documentation/stable/

Lancement : **bash run_experiments.sh**. Options détaillées dans README.md. Résultats dans results/results.json, results/profiles.csv et results/profiles.png.